

1. Introducere

1.1 Inteligența artificială, învățarea automată și învățarea profundă

Învățarea profundă este un subdomeniu al învățării automate care, la rândul ei, este un subdomeniu al inteligenței artificiale.

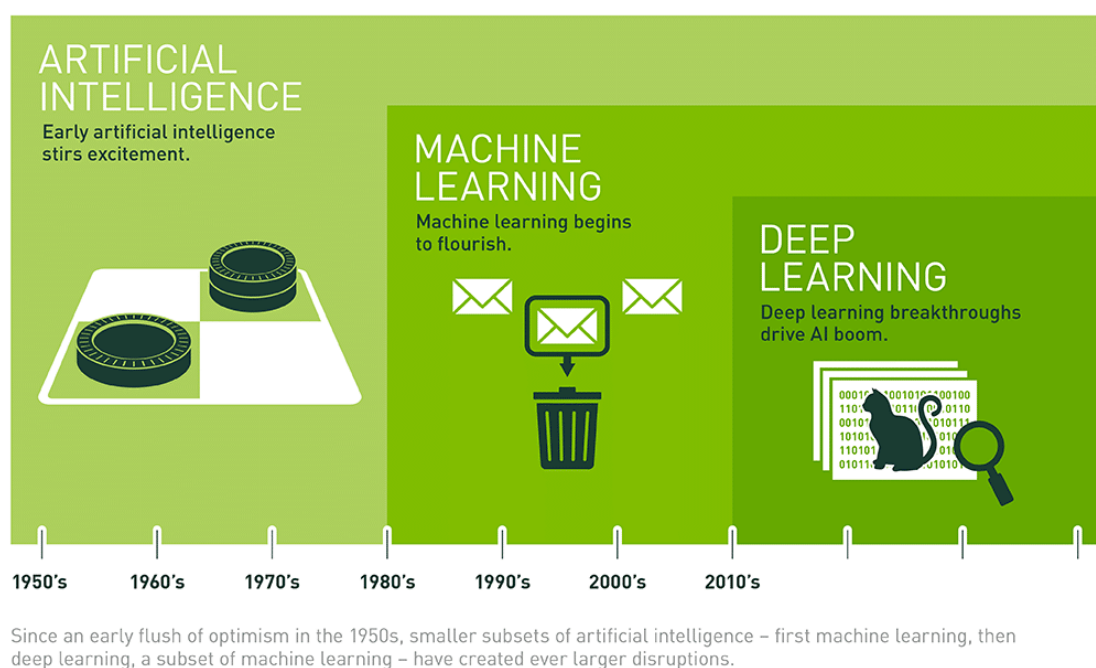


Fig. 1.1 Relația dintre inteligența artificială, învățarea automată și învățarea profundă (Copeland, 2016)

Conferința din 1956 de la Dartmouth este considerată ca fiind evenimentul fondator al inteligenței artificiale.

Conferința s-a desfășurat având următoarea propunere:

“The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer.”

1956 Dartmouth Conference: The Founding Fathers of AI




Fig. 1.2 Părinții fondatori ai inteligenței artificiale (Daftardar, 2018)

Pentru o lungă perioadă de timp, abordarea dominantă a fost inteligența artificială simbolică. Aceasta era potrivită pentru rezolvarea unor probleme logice, bine definite, dar s-a dovedit a fi dificil să se stabilească reguli explicite pentru rezolvarea unor probleme mai complexe, cum ar fi clasificarea imaginilor, recunoașterea vorbirii sau traducerea automată.

Modul tradițional de a rezolva probleme cu ajutorul calculatorului este ca un programator uman să scrie reguli (un program de calculator), care apoi transformă datele de intrare în răspunsuri adecvate.

Învățarea automată schimbă acest model: mașina analizează datele de intrare și răspunsurile corespunzătoare și își dă seama care ar trebui să fie regulile.

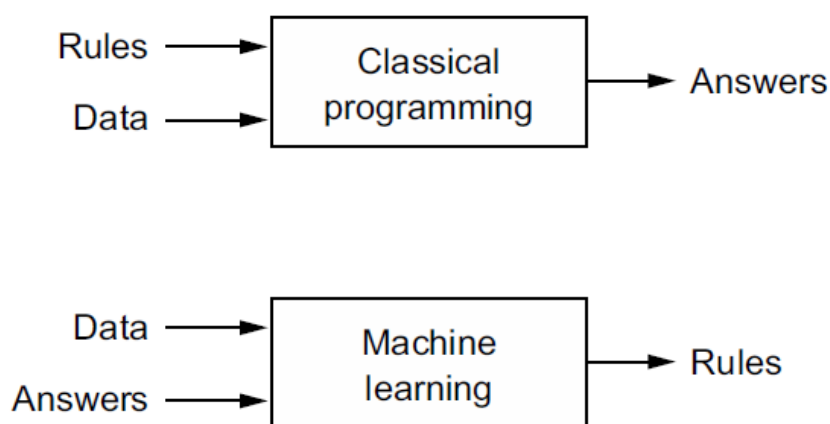




Fig. 1.3 Învățarea automată: un nou model de programare (Chollet, 2021)

Învățarea profundă, ca subdomeniu al învățării automate, pune accentul pe învățarea straturilor succesive de reprezentări ale datelor, din ce în ce mai semnificative, numărul de straturi reprezentând profunzimea modelului.

Pe lângă obținerea de performanțe mai bune, învățarea profundă facilitează rezolvarea problemelor, deoarece automatizează complet ceea ce obișnuia să fie cea mai importantă etapă din cadrul procesului de învățare automată, și anume, ingineria caracteristicilor.



Traditional machine learning uses hand-crafted features, which is tedious and costly to develop.



Deep learning learns hierarchical representation from the data itself, and scales with more data.

Fig. 1.4 Învățarea profundă comparativ cu învățarea automată (Ciptadi, 2019)

1.2 Evoluția rețelelor neuronale

În 1943, McCulloch și Pitts au propus un model simplificat al neuronului biologic cu ajutorul căruia se pot construi rețele care pot să efectueze calcule logice diverse.




Fig. 1.5 Calcule logice simple efectuate cu neuroni artificiali (Géron, 2022)

Perceptronul propus de Rosenblatt (1957) se bazează pe un neuron artificial ușor diferit, numit unitate logică cu prag, care calculează o sumă ponderată a intrărilor și apoi aplică o funcție de tip treaptă.




Fig. 1.6 Exemplu de perceptron cu două intrări (Ahmad, 2024)

Regula de învățare:

$$w_i^{(\text{next step})} = w_i + \eta(y - \hat{y})x_i$$

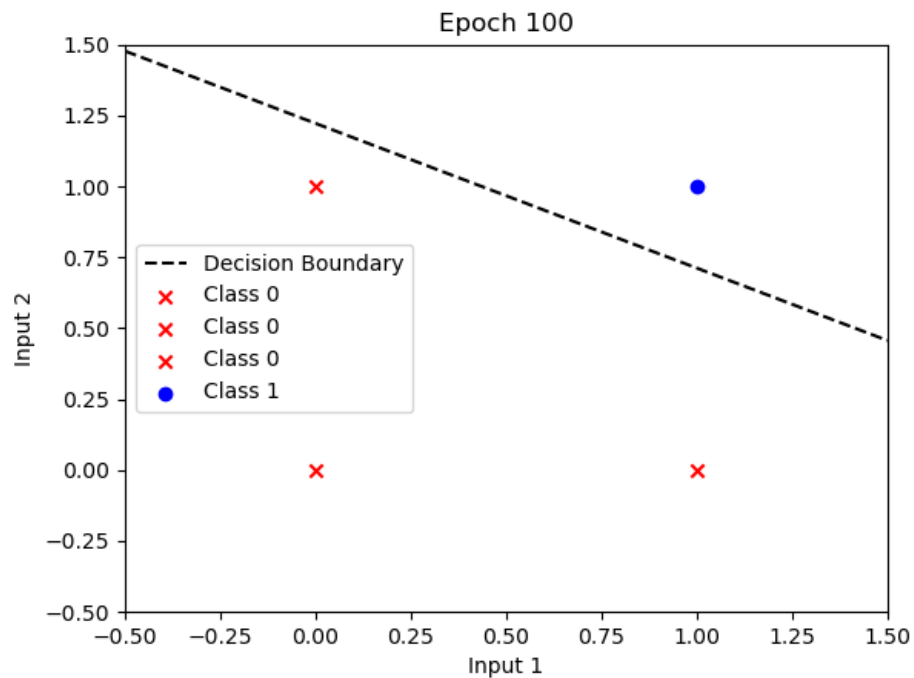


Fig. 1.7 Linia de separare a punctelor de date în cazul unui perceptron cu două intrări

În 1969, Minsky și Papert au evidențiat o serie de limitări ale perceptronului, în special faptul că nu poate rezolva unele probleme simple, cum ar fi funcția logică SAU Exclusiv (XOR).

Unele dintre limitările perceptronului pot fi eliminate cu ajutorul perceptronului multistrat (MLP). Timp de mulți ani, cercetătorii s-au străduit să găsească o modalitate de antrenare a perceptronului multistrat, dar fără succes. De abia în 1986, Rumelhart et al. au propus algoritmul de propagare înapoi a erorii, care este utilizat și în zilele noastre.

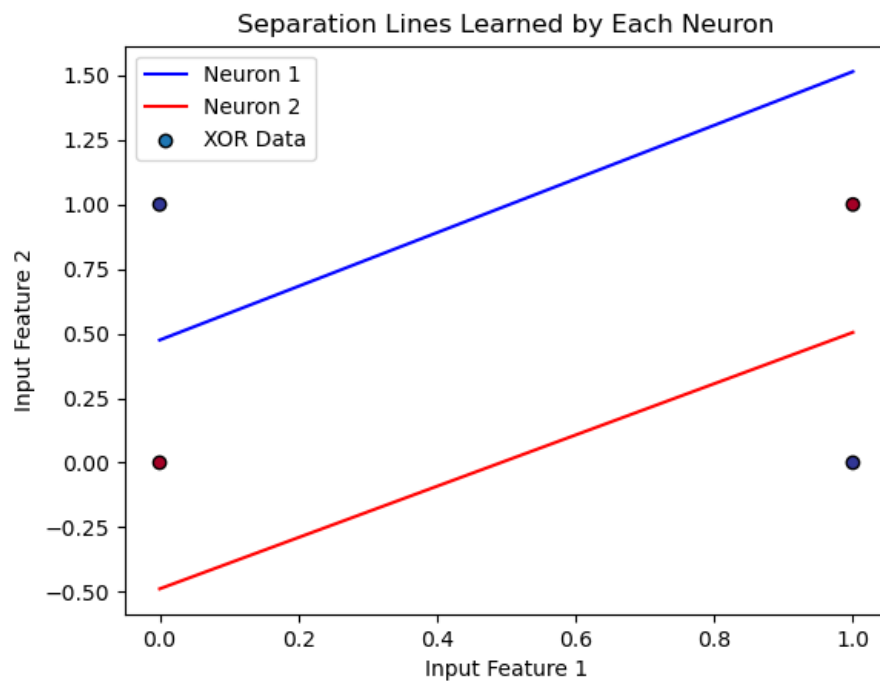


Fig. 1.8 Rezolvarea problemei XOR cu ajutorul perceptronului multistrat




Fig. 1.9 O rețea simplă folosită pentru ilustrarea algoritmului de propagare înapoi a erorii (Ekman, 2021)

1. Forward pass: Compute and store activation function output (y) for each neuron and finally the error

Resulting stored variables: y_g y_f $Error$



2. Backward pass: Compute the derivative $e'(y_f)$ of the error function. Compute (*back propagate*) the error for each neuron by multiplying the error from the subsequent neuron (that it feeds) by the weight to that neuron and then multiply by the derivative of its own activation function. (e.g. the error for neuron G is $error_g = error_f * w_{gf1} * g'(z_g)$ where $g'(z_g)$ is the derivative of the activation function for neuron G). This derivative can be computed from the stored output of the activation function.

Resulting stored variables: $error_g$ $error_f$ $e'(y_f)$



3. Update weights: For each weight, subtract ($learning_rate * input * error$) where input is the input value to that weight (from network input or output from preceding neuron) and error is the error term for the neuron the weight belongs to (e.g., for weight w_{gf1} the adjustment will be $-(learning_rate * y_g * error_f)$ where y_g is the output of neuron G).

Fig. 1.10 Algoritmul de propagare înapoi a erorii (Ekman, 2021)

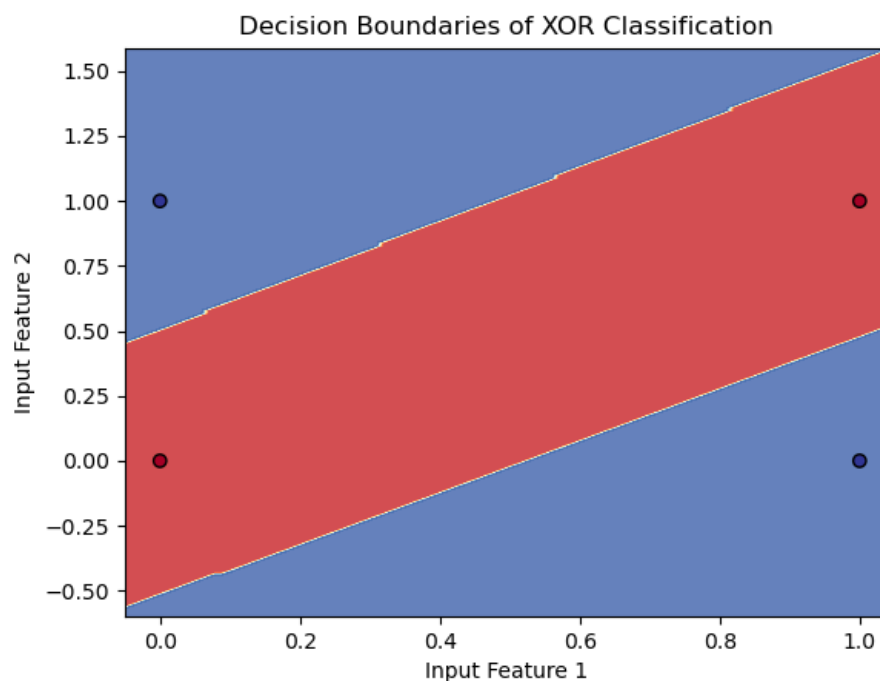


Fig. 1.11 Limitele de decizie în cazul problemei XOR

În funcție de modul în care sunt conectate nodurile, se poate crea o varietate de rețele neuronale.

Unul dintre cele mai utilizate tipuri de rețele neuronale utilizează o structură stratificată (fig. 1.12).




Fig. 1.12 Exemplu de rețea neuronală având o structură stratificată (Kim, 2017)

Rețelele neuronale au evoluat de la o arhitectură simplă, la o structură din ce în ce mai complexă (tabelul 1.1).

Tabelul 1.1 O clasificare a rețelelor neuronale (Kim, 2017)

Rețele neuronale cu un singur strat		Strat de intrare – Strat de ieșire
Rețele neuronale multistrat	Rețele neuronale superficiale	Strat de intrare – Strat ascuns – Strat de ieșire
	Rețele neuronale profunde	Strat de intrare – Straturi ascunse – Strat de ieșire

Această clasificare este motivată de dezvoltarea istorică a rețelelor neuronale.